Prediciendo la contaminación del aire en Madrid

María Medina - PiperLab
@mariamedp

PYCONES 2018 MÁLAGA

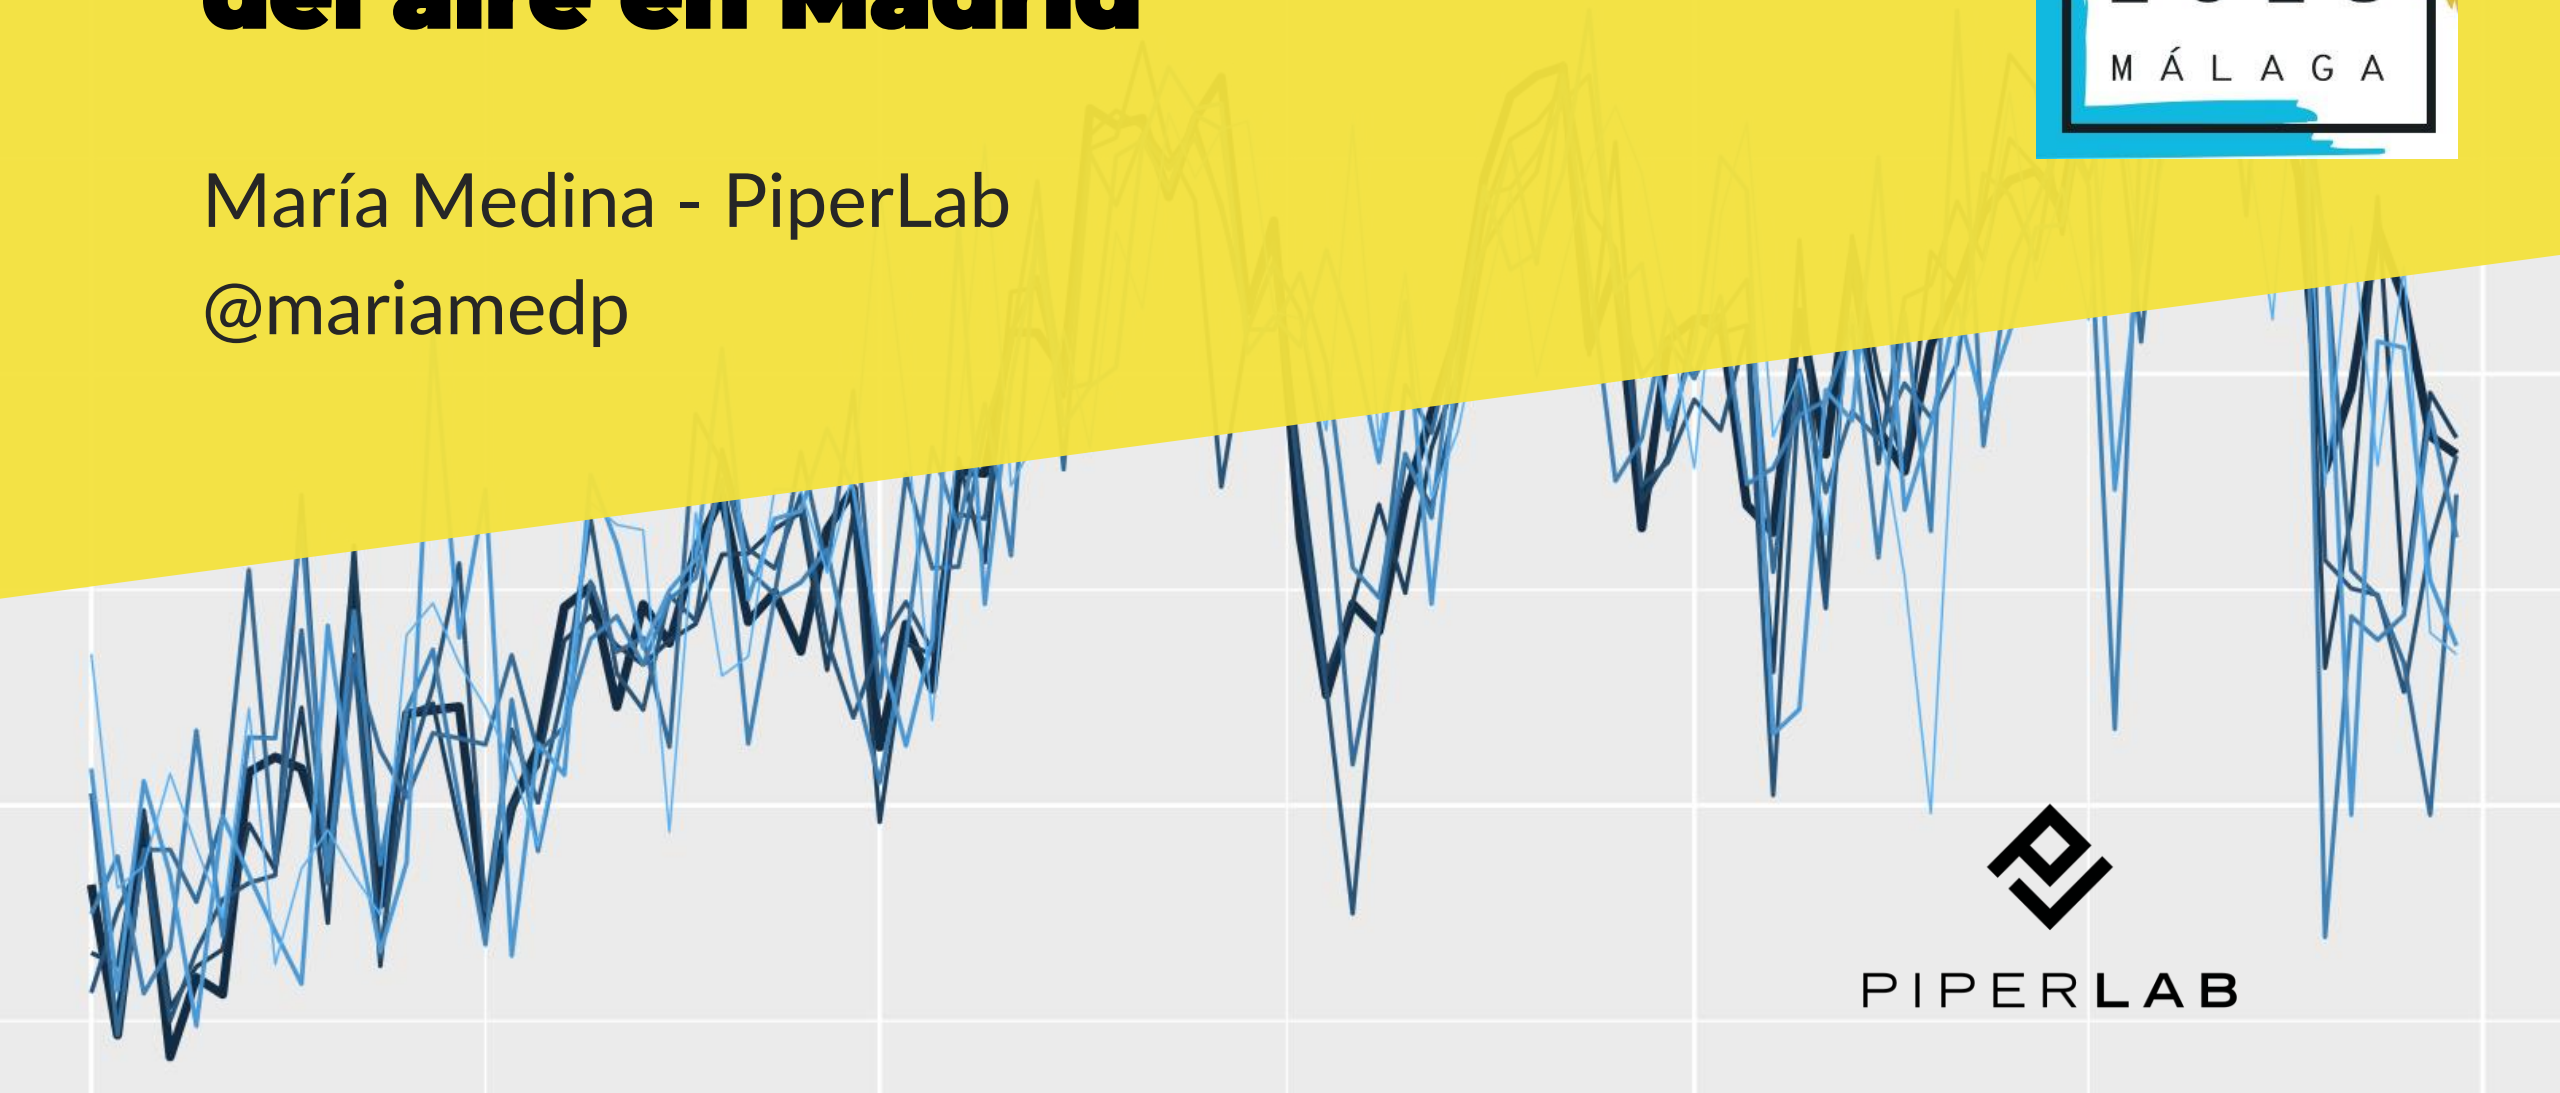

PIPERLAB

Hello my name is

María Medina

Data Scientist en PiperLab

Coorganizadora PyLadies Madrid

PIPERLAB

pyladies MADRID

@mariamedp

@PiperLab_es

www.piperlab.es

Érase una vez...

@mariamedp

@PiperLab_es

www.piperlab.es

Datos de contaminación

Portal de Datos Abiertos del Ayuntamiento de Madrid

Calidad del aire: Datos en tiempo real

Calidad del aire: Datos en tiempo real. El Sistema Integral de la **Calidad del Aire** del Ayuntamiento de Madrid permite conocer en cada momento los niveles de contaminación atmosférica en el municipio. En este conjunto de datos puede obtener la información actualizada en tiempo real, actualizándose estos datos cada hora, y...

Calidad del aire: Estaciones de control

Calidad del aire: Estaciones de control. El Sistema de Vigilancia está formado por 24 Estaciones Remotas automáticas que recogen la información básica para la vigilancia atmosférica. Poseen los analizadores necesarios para la medida correcta de los niveles de gases y de partículas. Las estaciones remotas son de varios tipos: Urbanas de fondo: representativas de la exposición...

Calidad del aire: Datos horarios años 2003 a 2016

Calidad del aire: Datos horarios años 2003 a 2016. El Sistema Integral de la **Calidad del Aire** del Ayuntamiento de Madrid permite conocer en cada momento los niveles de contaminación atmosférica en el municipio. En este conjunto de datos puede obtener la información recogida por las estaciones de control de

Calidad del aire: Datos diarios años 2003 a 2016

Calidad del aire: Datos diarios años 2003 a 2016. El Sistema Integral de la **Calidad del Aire** del Ayuntamiento de Madrid permite conocer en cada momento los niveles de contaminación atmosférica en el municipio. En este conjunto de datos puede obtener la información recogida por las estaciones de control de

@mariamedp

@PiperLab_es

www.piperlab.es

Cargar datos con pandas

pandas

$y_i t = \beta' x_{it} + \mu_i + \epsilon_{it}$

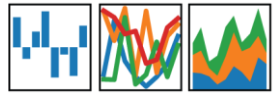

```
col_horas = ["{}_{}".format(h, tipo) for h in range(1, 25) for tipo in ("medida", "valido")]

datos = pd.read_csv("http://www.mambiente.munimadrid.es/opendata/horario.txt",
                    dtype="str",
                    names=["estacion_parte1", "estacion_parte2", "estacion_parte3",
                           "parametro", "tecnica", "periodo", "yyyy", "mm", "dd"] + col_horas)
datos.head()
```

	estacion_parte1	estacion_parte2	estacion_parte3	parametro	tecnica	periodo	yyyy	mm	dd	1_medida	...	20_medida	20_valido	21_medida	21_valido
0	28	079	004	01	38	02	2018	09	17	00009	...	00000	N	00000	N
1	28	079	004	06	48	02	2018	09	17	000.5	...	00000	N	00000	N
2	28	079	004	07	08	02	2018	09	17	00021	...	00000	N	00000	N
3	28	079	004	08	08	02	2018	09	17	00100	...	00000	N	00000	N
4	28	079	004	12	08	02	2018	09	17	00133	...	00000	N	00000	N

www.piperlab.es

@mariamedp

@PiperLab_es

Procesar datos con pandas

<estación, fecha, contaminante>	1_medida	1_valido	...	24_medida	24_valido
...	xxx	V/N	...	yyy	V/N

<estación, fecha, contaminante>	hora	medida	valido
...	1	xxx	V/N
...	...	...	...
...	24	yyy	V/N

www.piperlab.es

@mariamedp

@PiperLab_es

Procesar datos con pandas

<estación, fecha, contaminante>	1_medida	1_valido	...	24_medida	24_valido
...	xxx	V/N	...	yyy	V/N

`df.melt()`

<estación, fecha, contaminante>	variable	valor
	1_medida	xxx
	1_valido	V/N
	...	...
...	24_medida	yyy
	24_valido	V/N

`str.split("_")`

<estación, fecha, contaminante>	hora	variable	valor
	1	medida	xxx
	1	valido	V/N
	...	...	...
...	24	medida	yyy
	24	valido	V/N

`pd.pivot_table(df)`

<estación, fecha, contaminante>	hora	medida	valido
...	1	xxx	V/N
...	...	...	...
...	24	yyy	V/N

www.piperlab.es

@mariamedp

@PiperLab_es

Datóxido de Nitrógeno

@datoxnitro_bot

www.piperlab.es

@mariamedp

@PiperLab_es

Datóxido de Nitrógeno

@datoxnitro_bot

@mariamedp

@PiperLab_es

www.piperlab.es

Tuitear con Twython

Twython

```python
from twython import Twython

api = Twython(CONSUMER_KEY, CONSUMER_SECRET, ACCESS_KEY, ACCESS_SECRET)
```

```python
api.update_status(status = text)
```

```python
api.update_status(status = text,
                  in_reply_to_status_id = tweet_id)
```

```python
with open(mediafile, 'rb') as f:
    ret = api.upload_media(media=f)

api.update_status(status = text,
                  media_ids = ret["media_id"])
```

www.piperlab.es

¿Podemos predecir la contaminación?

www.piperlab.es

@mariamedp

@PiperLab_es

Proceso de predicción

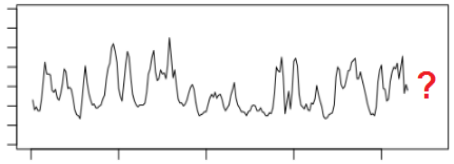

Histórico
contaminación

Variables **externas**

Meteorología,
Calendarios,
Tráfico, ...

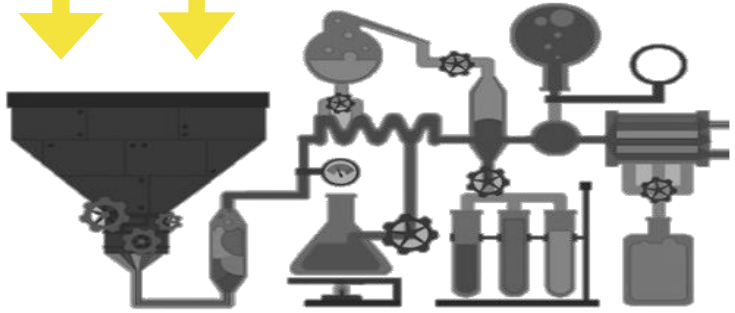

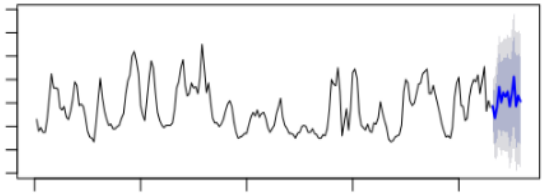

Predicción

Entrenamiento: algoritmo que
detecta **patrones en los datos**

www.piperlab.es

Reglas del protocolo

Mediciones **horarias** → Nivel de actuación **diario** → Escenario activado para el **día siguiente**

Niveles

Preaviso	2 estaciones de una zona alcanzan **180** µg/m^3 durante 2 horas consecutivas.
Aviso	2 estaciones de una zona alcanzan **200** µg/m^3 durante 2 horas consecutivas.
Alerta	3 estaciones de una zona alcanzan **400** µg/m^3 durante 3 horas consecutivas.

Escenarios

Escenario 1	1 día de preaviso.
Escenario 2	2 días consecutivos de preaviso o 1 de aviso.
Escenario 3	2 días consecutivos de aviso.
Escenario 4	3 días consecutivos de aviso o 1 día de alerta.

www.piperlab.es

Serie temporal “resumen”

Nivel **diario** protocolo:

2 estaciones	⇒ [2] media de las top 2 estaciones
de una zona	⇒ [4] cálculo por zona, y finalmente el máximo
alcanzan XXX	⇒ [1] ranking valores horarios
durante 2h consecutivas	⇒ [3] media móvil últimas 2 horas

www.piperlab.es

Serie temporal “resumen”

pandas

2 estaciones ⇒ [2] media de las top 2 estaciones (por hora)

de una zona ⇒ [4] cálculo por zona, y finalmente el máximo (por día)

alcanzan XXX ⇒ [1] ranking valores horarios

durante 2h consecutivas ⇒ [3] media móvil últimas 2 horas

```
datos[datos.valido == True].\
    sort_values("medida", ascending=False).\
    groupby(["zona", "datetime"]).\
    agg({'medida': lambda x: x.head(2).mean()}).\
    reset_index(drop=False).\
    groupby("zona").\
    rolling(window=2, on="datetime").mean().\
    drop("zona", axis=1).reset_index().\
    set_index("datetime").\
    groupby(lambda x: x.date).\
    agg({'medida': max})
```

Serie temporal “resumen”

pandas

2 estaciones ⇒ [2] media de las top 2 estaciones (por hora)

de una zona ⇒ [4] cálculo por zona, y finalmente el máximo (por día)

alcanzan XXX **⇒ [1] ranking valores horarios**

durante 2h consecutivas ⇒ [3] media móvil últimas 2 horas

```
datos[datos.valido == True].\
    sort_values("medida", ascending=False).\
    groupby(["zona", "datetime"]).\
    agg({'medida': lambda x: x.head(2).mean()}).\
    reset_index(drop=False).\
    groupby("zona").\
    rolling(window=2, on="datetime").mean().\
    drop("zona", axis=1).reset_index().\
    set_index("datetime").\
    groupby(lambda x: x.date).\
    agg({'medida': max})
```

@mariamedp

@PiperLab_es

www.piperlab.es

Serie temporal “resumen”

pandas

2 estaciones ⇒ **[2] media de las top 2 estaciones (por hora)**

de una zona ⇒ [4] cálculo por zona, y finalmente el máximo (por día)

alcanzan XXX ⇒ [1] ranking valores horarios

durante 2h consecutivas ⇒ [3] media móvil últimas 2 horas

```
datos[datos.valido == True].\
    sort_values("medida", ascending=False).\
    groupby(["zona", "datetime"]).\
    agg({'medida': lambda x: x.head(2).mean()}).\
    reset_index(drop=False).\
    groupby("zona").\
    rolling(window=2, on="datetime").mean().\
    drop("zona", axis=1).reset_index().\
    set_index("datetime").\
    groupby(lambda x: x.date).\
    agg({'medida': max})
```

www.piperlab.es

@mariamedp

@PiperLab_es

Serie temporal “resumen”

pandas

2 estaciones ⇒ [2] media de las top 2 estaciones (por hora)

de una zona ⇒ [4] cálculo por zona, y finalmente el máximo (por día)

alcanzan XXX ⇒ [1] ranking valores horarios

durante 2h consecutivas **⇒ [3] media móvil últimas 2 horas**

```
datos[datos.valido == True].\
    sort_values("medida", ascending=False).\
    groupby(["zona", "datetime"]).\
    agg({'medida': lambda x: x.head(2).mean()}).\
    reset_index(drop=False).\
    groupby("zona").\
    rolling(window=2, on="datetime").mean().\
    drop("zona", axis=1).reset_index().\
    set_index("datetime").\
    groupby(lambda x: x.date).\
    agg({'medida': max})
```

www.piperlab.es

@mariamedp

@PiperLab_es

Serie temporal “resumen”

2 estaciones ⇒ [2] media de las top 2 estaciones (por hora)

de una zona **⇒ [4] cálculo por zona, y finalmente el máximo (por día)**

alcanzan XXX ⇒ [1] ranking valores horarios

durante 2h consecutivas ⇒ [3] media móvil últimas 2 horas

```
datos[datos.valido == True].\
    sort_values("medida", ascending=False).\
    groupby(["zona", "datetime"]).\
    agg({'medida': lambda x: x.head(2).mean()}).\
    reset_index(drop=False).\
    groupby("zona").\
    rolling(window=2, on="datetime").mean().\
    drop("zona", axis=1).reset_index().\
    set_index("datetime").\
    groupby(lambda x: x.date).\
    agg({'medida': max})
```

www.piperlab.es

@mariamedp

@PiperLab_es

Modelos ARIMA base

StatsModels
Statistics in Python

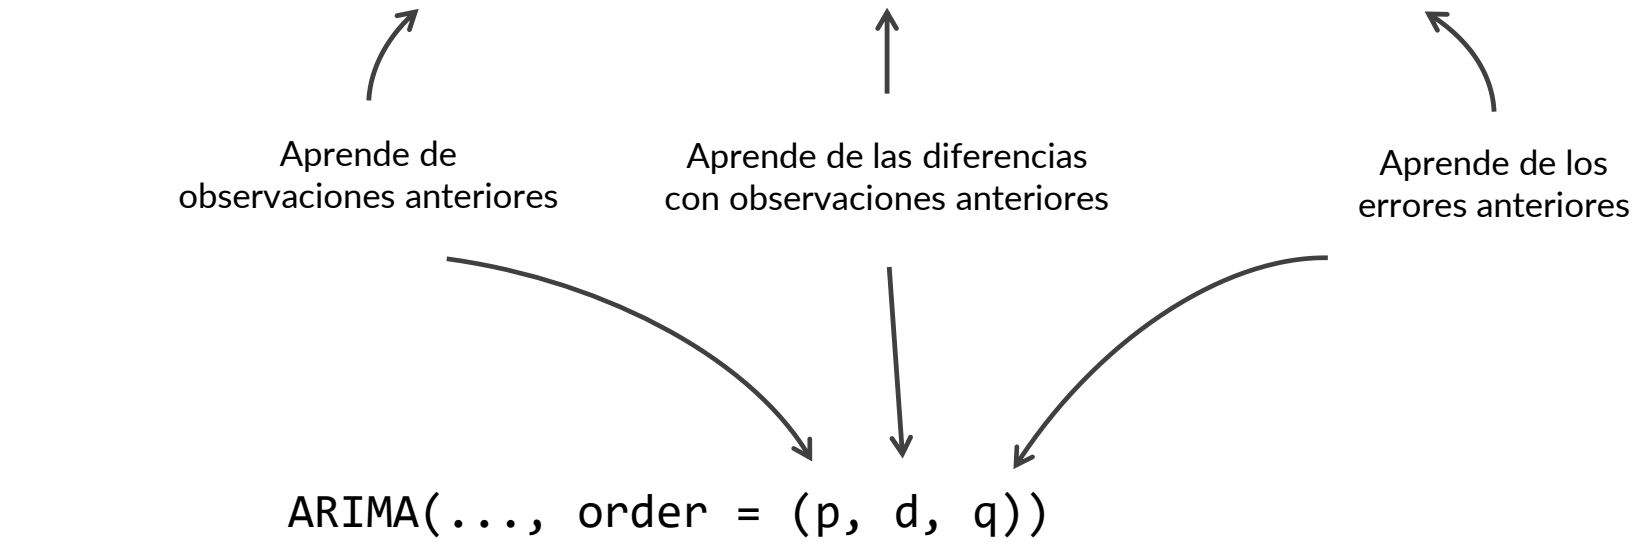

www.piperlab.es

PYCONES 2018 MÁLAGA

Modelos ARIMA base

Entrenar modelo

StatsModels
Statistics in Python

fecha	medida
2014-01-01	57.75
2014-01-02	75.75
2014-01-03	82.75
2014-01-04	57.25
2014-01-05	67.00
2014-01-06	87.50
2014-01-07	107.25
2014-01-08	135.75
2014-01-09	188.00

```
from statsmodels.tsa.arima_model import ARIMA

model_conf = ARIMA(seriecont, order=(2,1,3))
model_fit = model_conf.fit()
model_fit.summary()
```

ARIMA Model Results

Dep. Variable:	D.medida	**No. Observations:**	1460
Model:	ARIMA(2, 1, 3)	**Log Likelihood**	-7237.366
Method:	css-mle	**S.D. of innovations**	34.386
Date:	Tue, 18 Sep 2018	**AIC**	14488.732
Time:	16:02:10	**BIC**	14525.735
Sample:	01-02-2014	**HQIC**	14502.536
	- 12-31-2017		

www.piperlab.es

@mariamedp

@PiperLab_es

Modelos ARIMA base

Entrenar modelo

StatsModels
Statistics in Python

fecha	medida
2014-01-01	57.75
2014-01-02	75.75
2014-01-03	82.75
2014-01-04	57.25
2014-01-05	67.00
2014-01-06	87.50
2014-01-07	107.25
2014-01-08	135.75
2014-01-09	188.00

```
from statsmodels.tsa.arima_model import ARIMA

model_conf = ARIMA(seriecont, order=(2,1,3))
model_fit = model_conf.fit()
model_fit.summary()
```

ARIMA Model Results

Dep. Variable:	D.medida	**No. Observations:**	1460
Model:	ARIMA(2, 1, 3)	**Log Likelihood**	-7237.366
Method:	css-mle	**S.D. of innovations**	34.386
Date:	Tue, 18 Sep 2018	**AIC**	14488.732
Time:	16:02:10	**BIC**	14525.735
Sample:	01-02-2014	**HQIC**	14502.536
	- 12-31-2017		

www.piperlab.es

@mariamedp

@PiperLab_es

Modelos ARIMA base

Entrenar modelo

StatsModels
Statistics in Python

fecha	medida
2014-01-01	57.75
2014-01-02	75.75
2014-01-03	82.75
2014-01-04	57.25
2014-01-05	67.00
2014-01-06	87.50
2014-01-07	107.25
2014-01-08	135.75
2014-01-09	188.00

```
from statsmodels.tsa.arima_model import ARIMA

model_conf = ARIMA(seriecont, order=(2,1,3))
model_fit = model_conf.fit()
model_fit.summary()
```

ARIMA Model Results

Dep. Variable:	D.medida	**No. Observations:**	1460
Model:	ARIMA(2, 1, 3)	**Log Likelihood**	-7237.366
Method:	css-mle	**S.D. of innovations**	34.386
Date:	Tue, 18 Sep 2018	**AIC**	14488.732
Time:	16:02:10	**BIC**	14525.735
Sample:	01-02-2014	**HQIC**	14502.536
	- 12-31-2017		

www.piperlab.es

Modelos ARIMA base

Entrenar modelo

StatsModels
Statistics in Python

fecha	medida
2014-01-01	57.75
2014-01-02	75.75
2014-01-03	82.75
2014-01-04	57.25
2014-01-05	67.00
2014-01-06	87.50
2014-01-07	107.25
2014-01-08	135.75
2014-01-09	188.00

```
from statsmodels.tsa.arima_model import ARIMA

model_conf = ARIMA(seriecont, order=(2,1,3))
model_fit = model_conf.fit()
model_fit.summary()
```

ARIMA Model Results

Dep. Variable:	D.medida	**No. Observations:**	1460
Model:	ARIMA(2, 1, 3)	**Log Likelihood**	-7237.366
Method:	css-mle	**S.D. of innovations**	34.386
Date:	Tue, 18 Sep 2018	**AIC**	14488.732
Time:	16:02:10	**BIC**	14525.735
Sample:	01-02-2014	**HQIC**	14502.536
	- 12-31-2017		

www.piperlab.es

@mariamedp

@PiperLab_es

Modelos ARIMA base

Predecir todo seguido

StatsModels
Statistics in Python

```
ini_forecast = pd.Timestamp("2017-01-01", freq="D")
ndays = 7

end_forecast = ini_forecast + ndays - 1
```

```
model_conf = ARIMA(seriecont[:ini_forecast-1], order=(2,1,2), freq="D")
model_fit = model_conf.fit()

forecast = model_fit.forecast(ndays)[0]
forecast = pd.DataFrame(forecast, columns=["forecast"],
                        index=seriecont[ini_forecast:end_forecast].index)
```

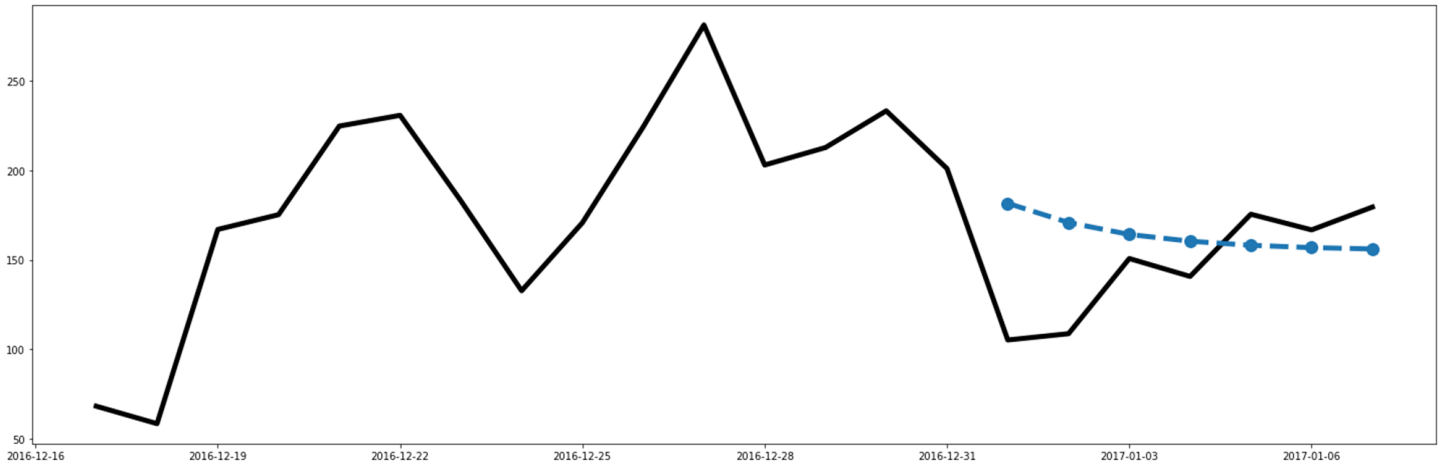

@mariamedp

@PiperLab_es

www.piperlab.es

Modelos ARIMA base

Predecir todo seguido

StatsModels
Statistics in Python

```
ini_forecast = pd.Timestamp("2017-01-01", freq="D")
ndays = 7

end_forecast = ini_forecast + ndays - 1
```

```
model_conf = ARIMA(seriecont[:ini_forecast-1], order=(2,1,2), freq="D")
model_fit = model_conf.fit()

forecast = model_fit.forecast(ndays)[0]
forecast = pd.DataFrame(forecast, columns=["forecast"],
                        index=seriecont[ini_forecast:end_forecast].index)
```

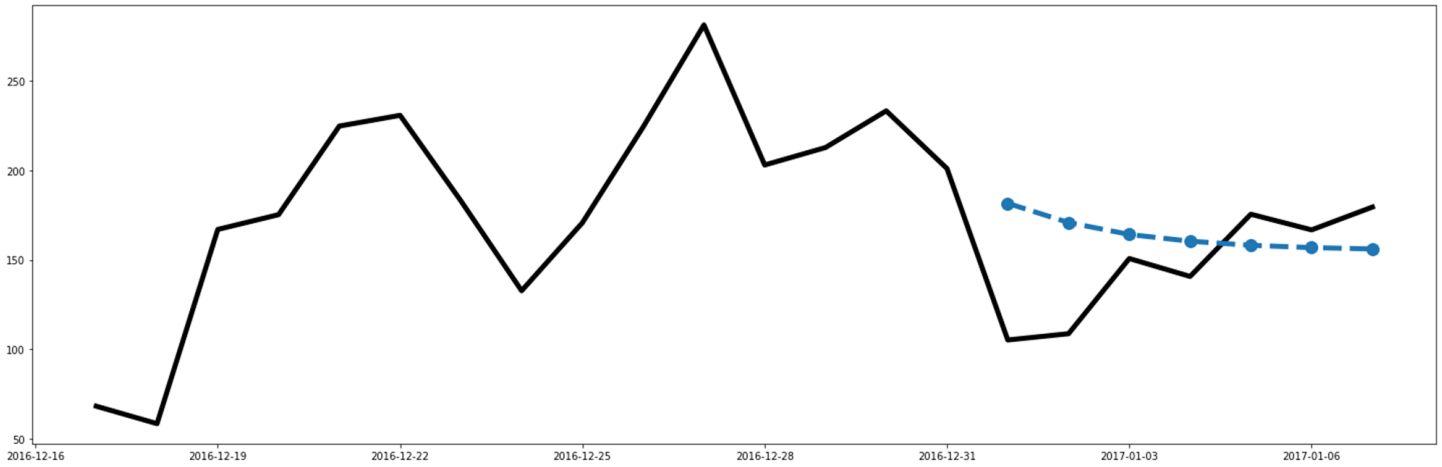

@mariamedp

@PiperLab_es

www.piperlab.es

Modelos ARIMA base

Predecir día a día

StatsModels
Statistics in Python

```
forecast_daily = []
for d in range(ndays):
    ini_test = ini_forecast + d
    modelconf_day = ARIMA(seriecont[:ini_test - 1], order=(2,1,2), freq="D")
    modelfit_day = modelconf_day.fit()
    forecast_daily.append(modelfit_day.forecast(1)[0])

forecast_daily = pd.DataFrame(forecast_daily, columns=["forecast"],
                              index=seriecont[ini_forecast:end_forecast].index)
```

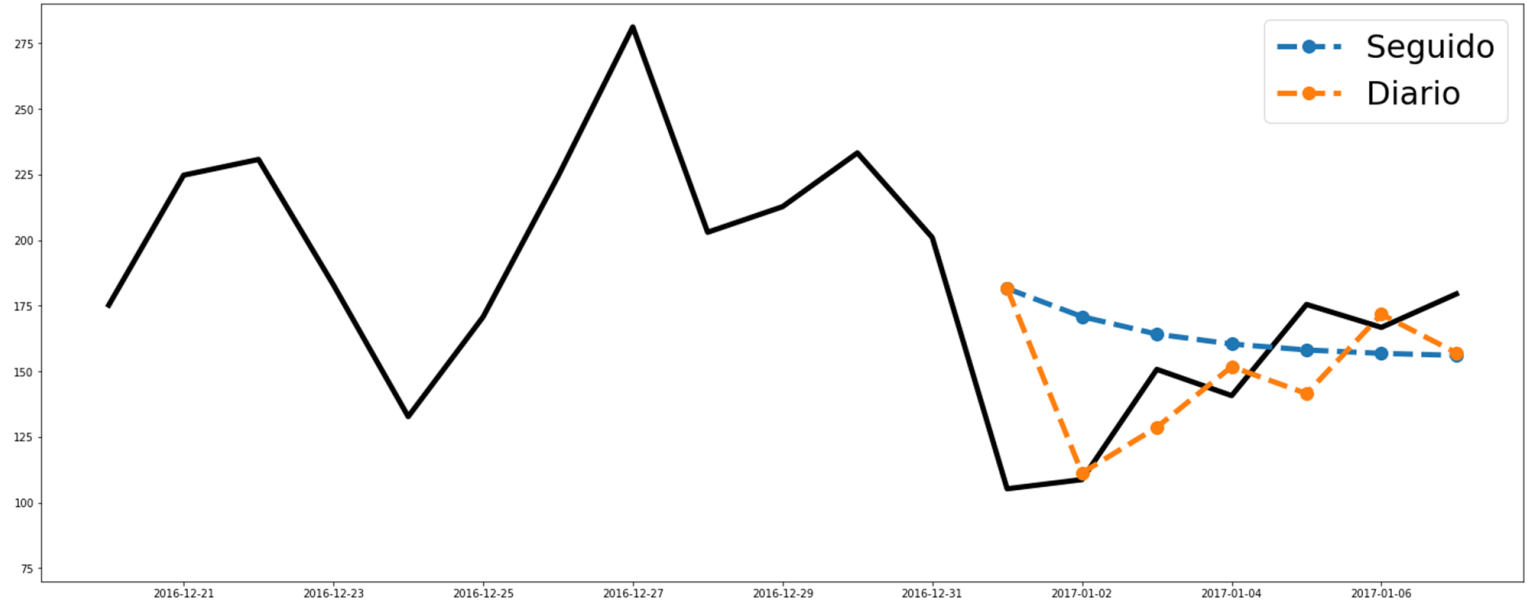

@mariamedp

@PiperLab_es

www.piperlab.es

Modelos ARIMA base

Predecir día a día

StatsModels
Statistics in Python

```
forecast_daily = []
for d in range(ndays):
    ini_test = ini_forecast + d
    modelconf_day = ARIMA(seriecont[:ini_test - 1], order=(2,1,2), freq="D")
    modelfit_day = modelconf_day.fit()
    forecast_daily.append(modelfit_day.forecast(1)[0])

forecast_daily = pd.DataFrame(forecast_daily, columns=["forecast"],
                              index=seriecont[ini_forecast:end_forecast].index)
```

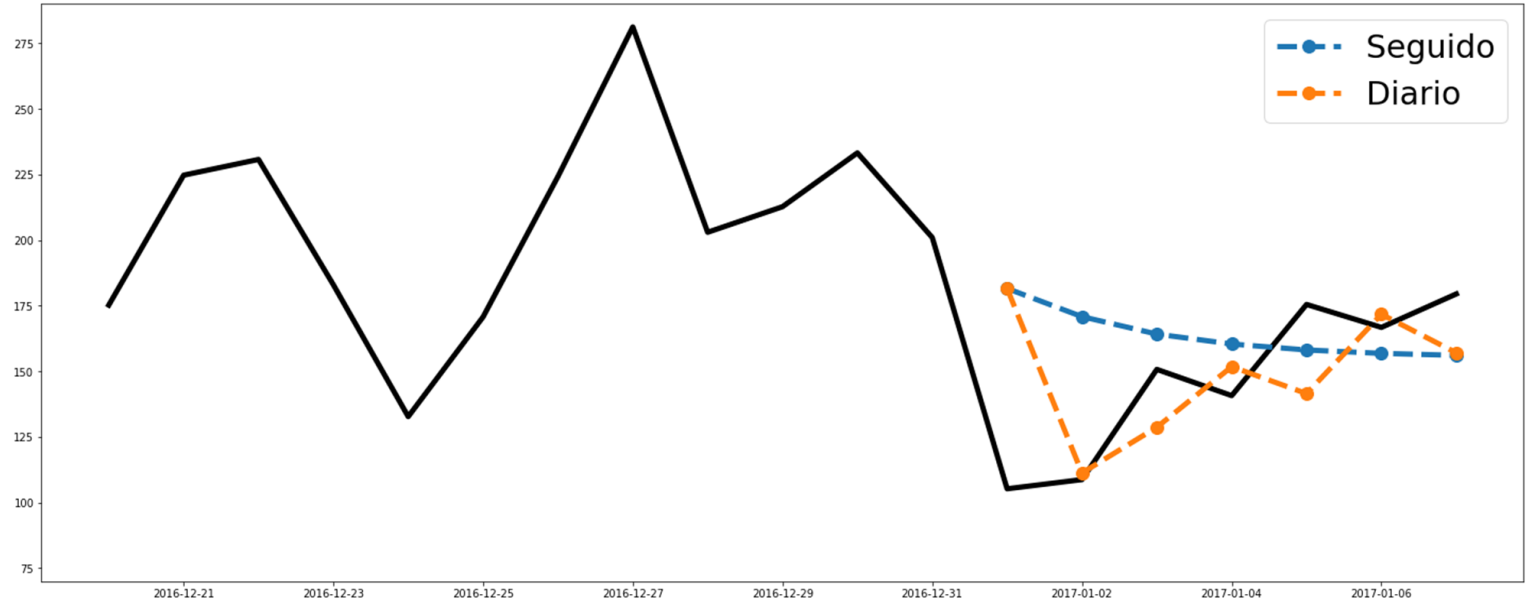

@mariamedp

@PiperLab_es

www.piperlab.es

Modelos ARIMA base

Predecir día a día

StatsModels
Statistics in Python

```
forecast_daily = []
for d in range(ndays):
    ini_test = ini_forecast + d
    modelconf_day = ARIMA(seriecont[:ini_test - 1], order=(2,1,2), freq="D")
    modelfit_day = modelconf_day.fit()
    forecast_daily.append(modelfit_day.forecast(1)[0])

forecast_daily = pd.DataFrame(forecast_daily, columns=["forecast"],
                              index=seriecont[ini_forecast:end_forecast].index)
```

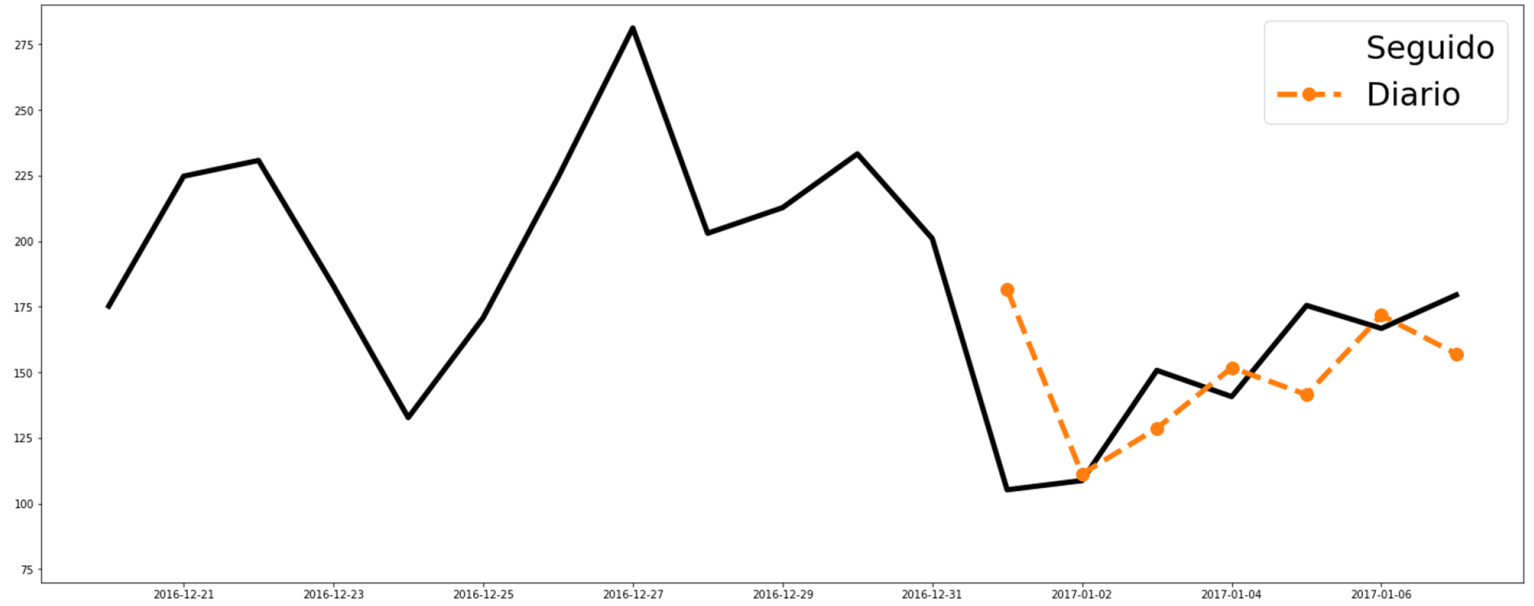

@mariamedp

@PiperLab_es

www.piperlab.es

Modelos con meteorología

Global Forecast System (GFS)

Datos = **predicciones** de contaminación

www.piperlab.es

Modelos con meteorología

Predecir día a día

StatsModels
Statistics in Python

```
forecast_daily_meteo = []
for d in range(ndays):
    ini_test = ini_forecast + d
    modelconf_day = ARIMA(seriecont[:ini_test-1], order=(1,0,1), freq="D",
                          exog = meteo_real[:ini_test-1])
    modelfit_day = modelconf_day.fit()
    forecast_daily_meteo.append(modelfit_day.forecast(1, exog=meteo_pred[ini_test:ini_test])[0])

forecast_daily_meteo = pd.DataFrame(forecast_daily_meteo, columns=["forecast"],
                                    index=seriecont[ini_forecast:end_forecast].index)
```

date	var4571	var9886	var8446	var5201	var3497	var11758	var6383	var3485	var8470	var16165	var8518	var3494	var8434	var8422	var72
2015-07-02	1536.03	212.7	55.0	1042.926667	5.731250	346.1	92266.2	6.925000	39.3	7987.500	37.9	10.3	45.4	47.4	35
2015-07-03	1559.85	212.4	59.5	1136.186667	7.340625	316.2	92378.7	8.133333	49.3	11725.000	63.9	9.5	43.4	59.5	40
2015-07-04	1572.43	212.6	53.3	916.513333	5.209375	310.3	92408.5	5.791667	47.1	7012.500	45.2	7.9	47.4	53.3	37
2015-07-05	1553.66	212.9	49.7	952.100000	5.243750	321.9	92323.7	6.866667	42.1	9000.000	35.3	8.5	34.7	49.7	37
2015-07-06	1559.65	212.0	39.6	1147.200000	4.612500	308.4	92270.4	6.208333	32.5	8750.025	27.6	7.4	32.1	39.6	30

www.piperlab.es

Modelos con meteorología

Predecir día a día

StatsModels
Statistics in Python

```
forecast_daily_meteo = []
for d in range(ndays):
    ini_test = ini_forecast + d
    modelconf_day = ARIMA(seriecont[:ini_test-1], order=(1,0,1), freq="D",
                          exog = meteo_real[:ini_test-1])
    modelfit_day = modelconf_day.fit()
    forecast_daily_meteo.append(modelfit_day.forecast(1, exog=meteo_pred[ini_test:ini_test])[0])

forecast_daily_meteo = pd.DataFrame(forecast_daily_meteo, columns=["forecast"],
                                    index=seriecont[ini_forecast:end_forecast].index)
```

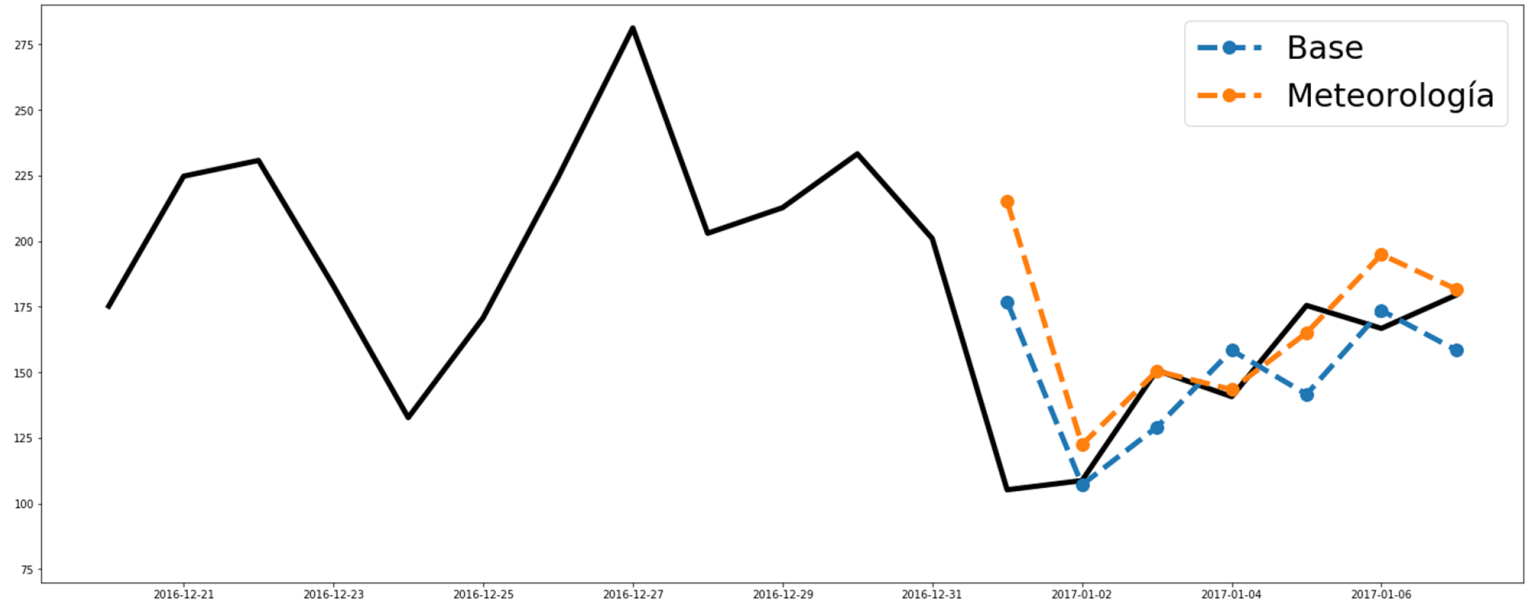

@mariamedp

@PiperLab_es

www.piperlab.es

Modelos con meteorología

Predecir día a día

StatsModels
Statistics in Python

```
forecast_daily_meteo = []
for d in range(ndays):
    ini_test = ini_forecast + d
    modelconf_day = ARIMA(seriecont[:ini_test-1], order=(1,0,1), freq="D",
                          exog = meteo_real[:ini_test-1])
    modelfit_day = modelconf_day.fit()
    forecast_daily_meteo.append(modelfit_day.forecast(1, exog=meteo_pred[ini_test:ini_test])[0])

forecast_daily_meteo = pd.DataFrame(forecast_daily_meteo, columns=["forecast"],
                                    index=seriecont[ini_forecast:end_forecast].index)
```

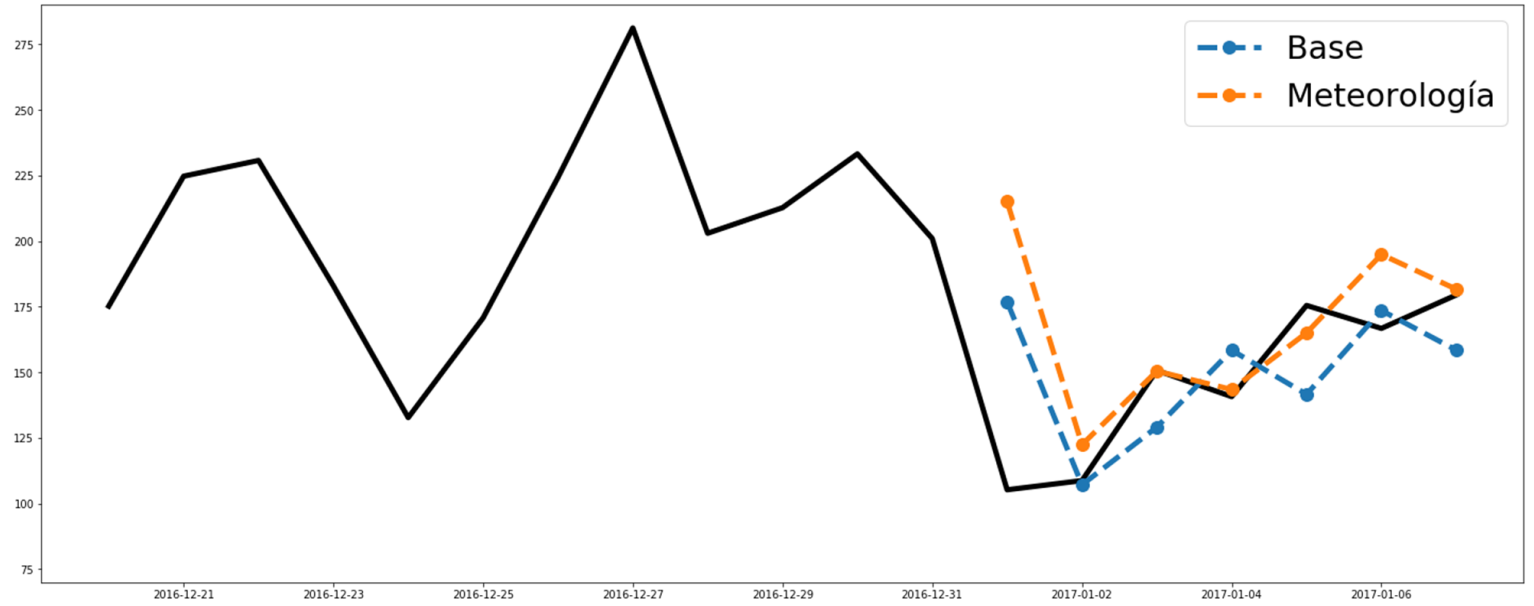

@mariamedp

@PiperLab_es

www.piperlab.es

Modelos con meteorología

Variables más relevantes

- Altura geopotencial
- Temperatura
- Humedad relativa
- Altura de la capa límite planetaria
- Velocidad del viento
- Ozono
- Presión
- Ventilación

www.piperlab.es

@mariamedp

@PiperLab_es

Transformación de variables: PCA

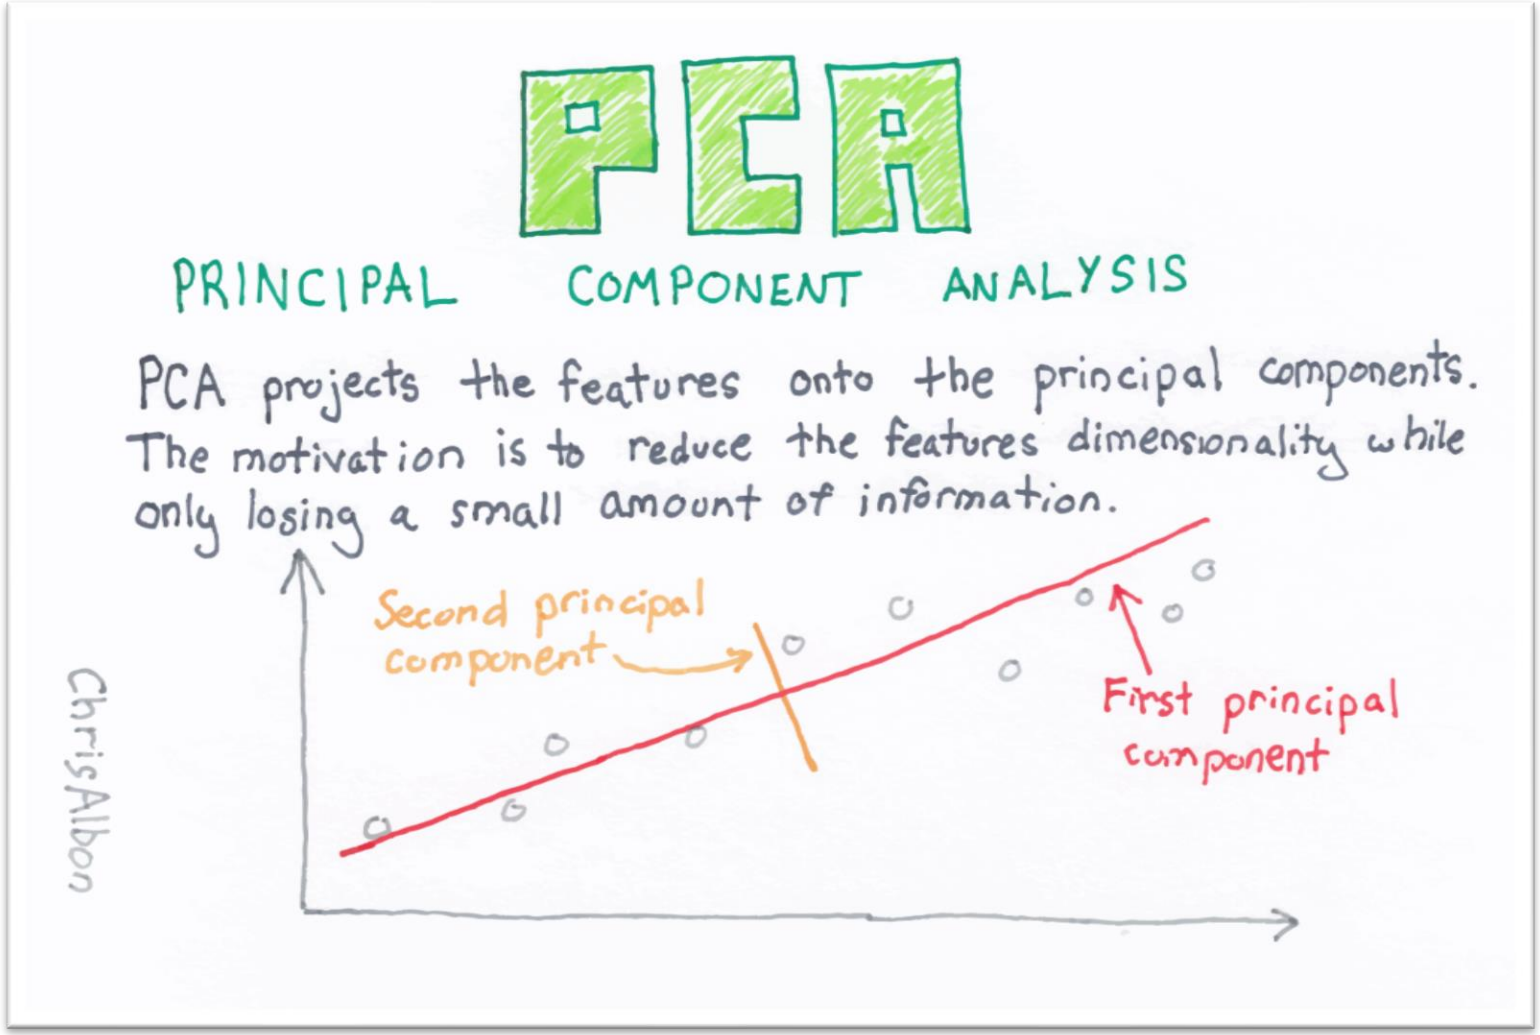

@chrisalbon

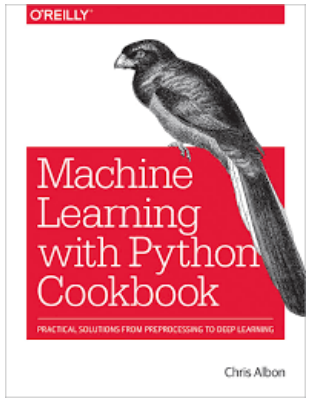

www.piperlab.es

Aplicar PCA

```python
from sklearn.preprocessing import StandardScaler
from sklearn.decomposition import PCA

scaler = StandardScaler().fit(meteo_real)

meteo_real_scaled = scaler.transform(meteo_real)
meteo_pred_scaled = scaler.transform(meteo_pred)

pca = PCA(n_components=10).fit(meteo_real_scaled)

meteo_real_pca = pca.transform(meteo_real_scaled)
meteo_pred_pca = pca.transform(meteo_pred_scaled)

meteo_real_pca = pd.DataFrame(meteo_real_pca, index=meteo_real.index)
meteo_pred_pca = pd.DataFrame(meteo_pred_pca, index=meteo_pred.index)
```

date	0	1	2	3	4	5	6	7	8	9
2015-07-02	-0.504376	2.798512	-0.852335	-0.780081	-0.895056	-0.257762	-0.308637	0.076789	0.334893	-0.353400
2015-07-03	0.082084	3.036624	1.045996	-1.167916	-0.607475	-0.472422	0.669803	0.270863	-0.188384	-0.172179
2015-07-04	-1.604054	1.966525	0.330712	-0.998042	-0.176281	-0.312145	0.350273	0.609419	-0.170290	0.277479
2015-07-05	-1.451573	2.818816	-0.033557	-0.860587	-0.102741	-0.229093	0.357474	0.695917	-0.199327	-0.123499
2015-07-06	-1.815973	3.705881	-0.157315	-1.223369	-0.006324	-1.004604	0.717226	0.359217	-0.540903	-0.190084

@mariamedp

@PiperLab_es

www.piperlab.es

Aplicar PCA

```python
from sklearn.preprocessing import StandardScaler
from sklearn.decomposition import PCA

scaler = StandardScaler().fit(meteo_real)

meteo_real_scaled = scaler.transform(meteo_real)
meteo_pred_scaled = scaler.transform(meteo_pred)

pca = PCA(n_components=10).fit(meteo_real_scaled)

meteo_real_pca = pca.transform(meteo_real_scaled)
meteo_pred_pca = pca.transform(meteo_pred_scaled)

meteo_real_pca = pd.DataFrame(meteo_real_pca, index=meteo_real.index)
meteo_pred_pca = pd.DataFrame(meteo_pred_pca, index=meteo_pred.index)
```

date	0	1	2	3	4	5	6	7	8	9
2015-07-02	-0.504376	2.798512	-0.852335	-0.780081	-0.895056	-0.257762	-0.308637	0.076789	0.334893	-0.353400
2015-07-03	0.082084	3.036624	1.045996	-1.167916	-0.607475	-0.472422	0.669803	0.270863	-0.188384	-0.172179
2015-07-04	-1.604054	1.966525	0.330712	-0.998042	-0.176281	-0.312145	0.350273	0.609419	-0.170290	0.277479
2015-07-05	-1.451573	2.818816	-0.033557	-0.860587	-0.102741	-0.229093	0.357474	0.695917	-0.199327	-0.123499
2015-07-06	-1.815973	3.705881	-0.157315	-1.223369	-0.006324	-1.004604	0.717226	0.359217	-0.540903	-0.190084

@mariamedp

@PiperLab_es

www.piperlab.es

Aplicar PCA

```python
from sklearn.preprocessing import StandardScaler
from sklearn.decomposition import PCA

scaler = StandardScaler().fit(meteo_real)

meteo_real_scaled = scaler.transform(meteo_real)
meteo_pred_scaled = scaler.transform(meteo_pred)

pca = PCA(n_components=10).fit(meteo_real_scaled)

meteo_real_pca = pca.transform(meteo_real_scaled)
meteo_pred_pca = pca.transform(meteo_pred_scaled)

meteo_real_pca = pd.DataFrame(meteo_real_pca, index=meteo_real.index)
meteo_pred_pca = pd.DataFrame(meteo_pred_pca, index=meteo_pred.index)
```

date	0	1	2	3	4	5	6	7	8	9
2015-07-02	-0.504376	2.798512	-0.852335	-0.780081	-0.895056	-0.257762	-0.308637	0.076789	0.334893	-0.353400
2015-07-03	0.082084	3.036624	1.045996	-1.167916	-0.607475	-0.472422	0.669803	0.270863	-0.188384	-0.172179
2015-07-04	-1.604054	1.966525	0.330712	-0.998042	-0.176281	-0.312145	0.350273	0.609419	-0.170290	0.277479
2015-07-05	-1.451573	2.818816	-0.033557	-0.860587	-0.102741	-0.229093	0.357474	0.695917	-0.199327	-0.123499
2015-07-06	-1.815973	3.705881	-0.157315	-1.223369	-0.006324	-1.004604	0.717226	0.359217	-0.540903	-0.190084

Modelos con meteorología PCA

Predecir día a día

StatsModels
Statistics in Python

```
forecast_daily_pca = []
for d in range(ndays):
    ini_test = ini_forecast + d
    modelconf_day = ARIMA(seriecont[:ini_test-1], order=(1,0,1), freq="D",
                          exog = meteo_real_pca[:ini_test-1])
    modelfit_day = modelconf_day.fit()
    forecast_daily_pca.append(modelfit_day.forecast(1, exog=meteo_pred_pca[ini_test:ini_test])[0])

forecast_daily_pca = pd.DataFrame(forecast_daily_pca, columns=["forecast"],
                                  index=seriecont[ini_forecast:end_forecast].index)
```

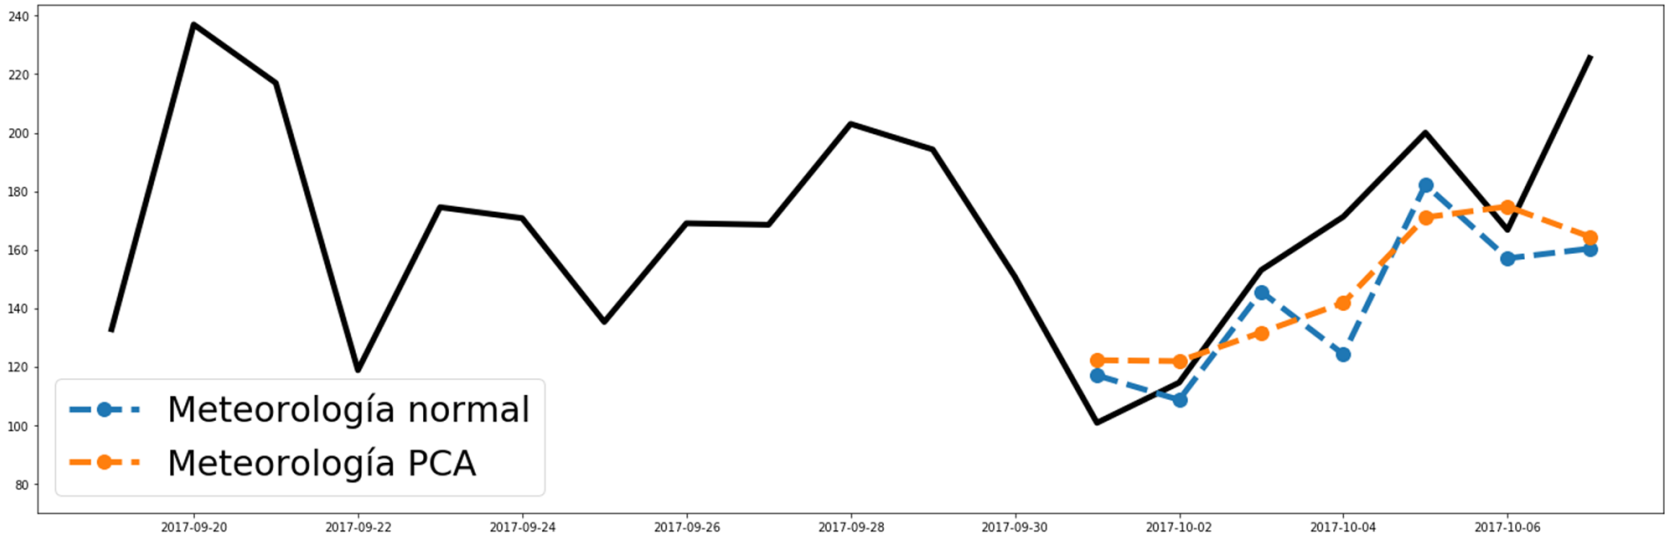

www.piperlab.es

@mariamedp

@PiperLab_es

Modelos con meteorología PCA

Predecir día a día

StatsModels
Statistics in Python

```
forecast_daily_pca = []
for d in range(ndays):
    ini_test = ini_forecast + d
    modelconf_day = ARIMA(seriecont[:ini_test-1], order=(1,0,1), freq="D",
                          exog = meteo_real_pca[:ini_test-1])
    modelfit_day = modelconf_day.fit()
    forecast_daily_pca.append(modelfit_day.forecast(1, exog=meteo_pred_pca[ini_test:ini_test])[0])

forecast_daily_pca = pd.DataFrame(forecast_daily_pca, columns=["forecast"],
                                  index=seriecont[ini_forecast:end_forecast].index)
```

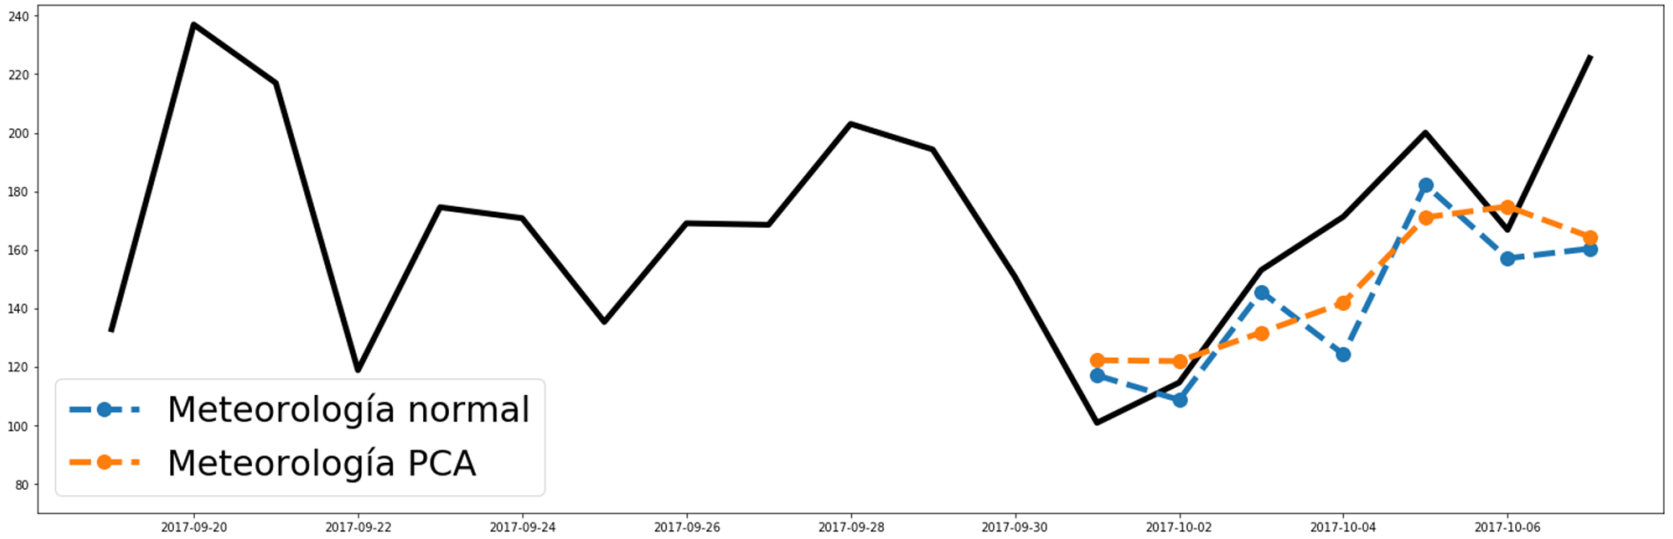

www.piperlab.es

@mariamedp

@PiperLab_es

Proyecto

Iteraciones

www.piperlab.es

@mariamedp

@PiperLab_es

Proyecto

Resultados

Horizonte	Precisión (accuracy)	Detección picos (recall)
24 horas	87.98%	**90.24%**
48 horas	87.36%	73.17%
7 días	77.97%	51.22%

www.piperlab.es

#PyConES18

¡Gracias!

@mariamedp